EDA NLP | AG NEWS

Pipeline de preprocesamiento y diagnóstico del corpus

Ejecución: SPACY / en_core_web_sm

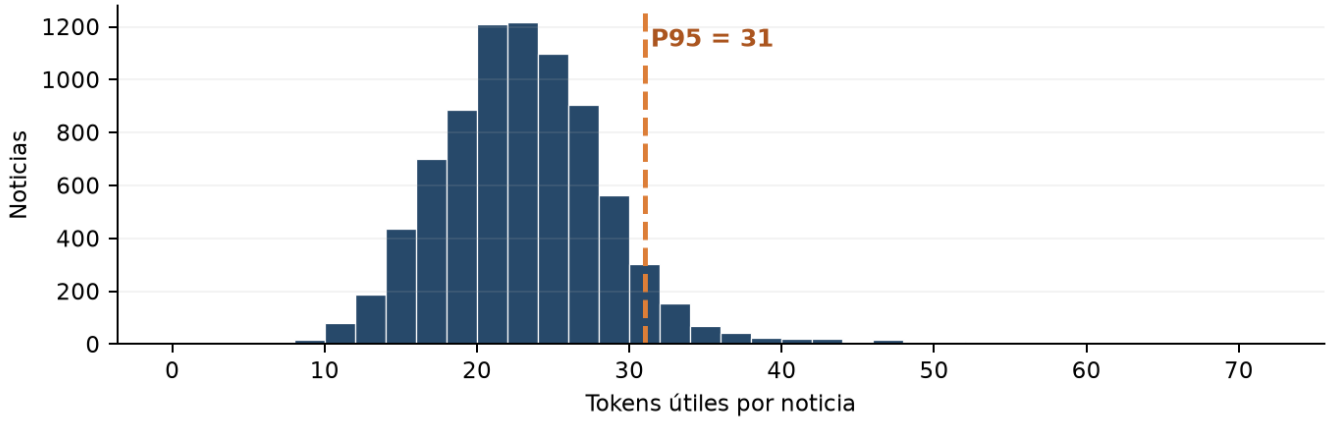
TRAIN	CLASES	P95	MEDIANA
8.000	4	31	22

01 PREPROCESAMIENTO

HTML → minúsculas → tokens → lemas → stop-words

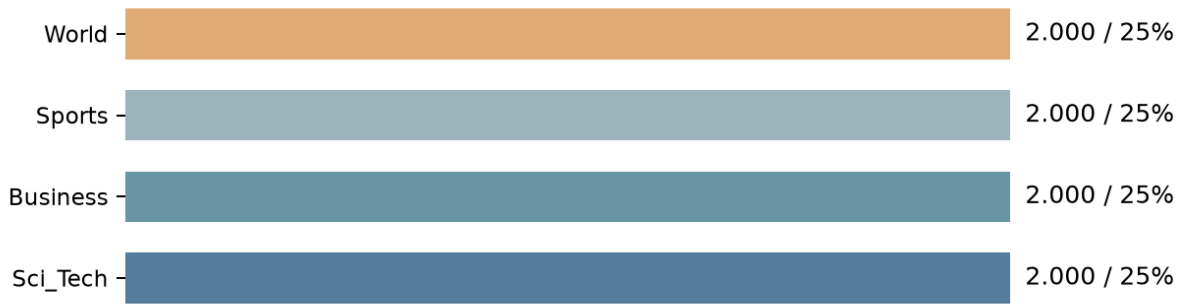
Negaciones conservadas; sin usar el conjunto de test.

02 LONGITUD DE LOS DOCUMENTOS



95.2% de las noticias tiene hasta 31 tokens; máximo: 70.

03 DISTRIBUCIÓN DE CLASES



Balance perfecto: 2.000 noticias por clase de entrenamiento.

Control de calidad: 359 textos con HTML; 38/50 palabras comunes eran stop-words.

Nota: P95 de palabras; Transformers requieren medir subwords por separado.

N-GRAMAS DEL CORPUS

20 bigramas y 20 trigramas · conteos sobre train

	BIGRAMAS	N	TRIGRAMAS	N
01	new york	419	boston red sox	37
02	oil price	197	new york stock	36
03	united states	166	high oil price	27
04	prime minister	139	prime minister ariel	26
05	red sox	98	minister ariel sharon	25
06	los angeles	96	new york yankees	22
07	san francisco	96	secretary state colin	22
08	president bush	93	state colin powell	22
09	year old	88	president vladimir putin	21
10	sport network	74	crude oil price	20
11	e mail	73	international space station	18
12	mobile phone	72	minister tony blair	17
13	wall street	71	president george bush	17
14	microsoft corp	70	prime minister tony	17
15	kill people	69	initial public offering	16
16	world cup	69	los angeles dodger	16
17	chief executive	67	security exchange commission	16
18	european union	65	mart stores inc	15
19	world large	63	oil price rise	15
20	year ago	62	osama bin laden	15

04 INTERPRETACIÓN

Los N-gramas muestran entidades y temas relevantes, sin etiquetas HTML.

05 CONCLUSIÓN

Corpus sin nulos y balanceado: apto para clasificar con TF-IDF.

Se eliminaron marcas HTML y ruido, conservando negaciones.

Para M4, calcular max_len con el tokenizador subword del Transformer.